# **ЖИТИТА**



# Backup- und Recoverystrategie für Db2 z/OS auf dem IBM Mainframe mittels IBM- und BMC-Tools

### BACHELORARBEIT

für die Prüfung zum

Bachelor of Science

des Studienganges Informatik / Angewandte Informatik

an der

Dualen Hochschule Baden-Württemberg Karlsruhe

von

Patrick Frey

Abgabedatum 4. September 2023

Bearbeitungszeitraum 12 Wochen Matrikelnummer 3946606 Kurs tinf20b2 Ausbildungsfirma Atruvia AG

Karlsruhe

Betreuer der Ausbildungsfirma Rolf Merkle Gutachter der Studienakademie Michael Vetter

Erklärung
Ich versichere hiermit, dass ich meine Bachelorarbeitmit dem Thema: »Backupund Recoverystrategie für Db2 z/OS auf dem IBM Mainframe mittels IBM- und BMC-Tools« selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.
Ort Datum Unterschrift

## Sperrvermerk

Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungsprozesses und des Evaluationsverfahrens zugänglich gemacht werden, sofern keine anderslautende Genehmigung vom Dualen Partner vorliegt.

# Inhaltsverzeichnis

1	Auf	gabe ur	nd Ziel	1
2	Ein	führung	g ins Mainframe	3
	2.1	Z Syste	ems	3
			Was ist ein Mainframe	
		2.1.2	Aufbau Mainframe	4
	2.2			
			Db2	
			TSO	
			IWS	
3	Mig	ration		7
	3.1			7
	3.2	Datenn	nigration	7
			DDL	
			Datenmigration	
4	Rec	overyst	trategie	8
	4.1	•	le Backuptstrategie	8
			Indizes	
			Activelog vs. Archivelog	

# Abbildungsverzeichnis

# Tabellenverzeichnis

2.1	Meine Tabelle																																			4
	michie Idoene	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	•	-

# Abkürzungsverzeichnis

SLA Service Level Agreements
EDV elektronische Datenverarbeitung
HW Hardware
SW Software
OLAP Online Analytical Processing
OLTP Online Transaction Processing
OS Betriebssystem
<b>DWH</b> Data Ware House
LPAR Logical Partition
Sysplex System Complex
CF Coupling Facility
DB Datenbank
TS Tablespace

TABELLENVERZEICHNIS									
DBMS Datenbankmanagementsystem		1							

# 1. Aufgabe und Ziel

#### Umfeld

Die Atruvia AG ist in Geschäfts- und Servicefelder unterteilt. Das Servicefeld Plattformservices stellt die technischen Grundlagen für dritte, wertschöpfende Dienstleistungen bereit. Der Plattformservice Databaseservices betreibt alle zentralen Datenbanken, die für die Kerngeschäftsprozesse benötigt werden. Die vorwiegende Technologie ist Db2  $\rm z/OS$  von IBM. Während die meisten modernen Datenbankmanagementsysteme (DBMS), wie Oracle oder MSSQL, auf Servern laufen, setzt IBM auf sein eigenes Mainframe, das  $\rm Z$  Systems.

#### Aufgabe

Ein Datenbanksystem muss zu jeder Zeit wiederherstellbar sein. Äußere Einflüsse wie Naturkatastrophen, innnere Störungen durch Hardwareschäden oder menschliches Fehlverhalten kann dazu führen, dass Daten korrupt, inkonsitent oder fachlich falsch sind. In diesen Fällen muss ein funktionierender Stand wiederhergestellt werden. Das Unternehmen hat dahingehend Service Level Agreements (SLA) mit den Kunden, welche die erlaubte nicht-Verfügbarkeit vorgeben. Um das sicherzustellen, soll eine Backup- und Recoverystrategie entwickelt werden. Bestandteil dieser Strategie sind verschiedene Parameter wie Copy-Bestandteile und verwendetes Tool. Als Nebenfaktoren sollen Speicherkomplexität des Backups und die Laufzeitkomplexität der Recovery berücksichtigt werden.

Mittels Zwischenergebnissen werden Kosten bestimmt und eine Laufzeitprognosen erstellt. Diese dienen der Vorbereitung auf den finalen Schritt: Die Recovery eines gesamten Datenbanksubsystems.

Zur Ergebnisverfikation wird ein Tool entwickelt, welches die Integrität des recoverten Subsystems überprüft. Dafür müssen betroffenen Datenbanken (DBs) und Tablespaes (TSs) identifiziert und auf Vollständigkeit geprüft werden.

#### gewünschtes Ergebnis

Konkretisie

Am Ende soll eine praktikable Recoverystrategie stehen. Diese beinhaltet den Inhalt des Backups wie Indizes oder Views. Eine Empfehlung soll ausgestellt werden über die

Durchführung der Recovery, welche Methode, welche Tools sollen verwendet werden. Dies ist über Speicher- und Laufzeitkomplexität zu begründen.

Außerdem muss das Ergebnis verifiziert werden. Dafür muss die eigens entwickelte Anwendung einen Healthcheck ausführen indem die Vollständigkeit des Backups geprüft wird. Zusätzlich soll die Komplexität einer Recovery prognostiziert werden.

# 2. Einführung ins Mainframe

#### 2.1 Z Systems

Im Rahmen dieser Bachelorarbeit wird keine dezentrale Software entwickelt, sondern zentral auf dem IBM Mainframe (früher Großrechner) entwickelt. In der Atruvia AGwird das Flaggschiff von IBM eingesetzt, das Z Systems, aktuell in der 15. Generation. Das Mainframe ist eine besondere Art Computer, die mitunter ähnliche Aufgaben erfüllt wie ein Server. Jedoch treten zum Teil wesentliche Unterschiede auf.

#### 2.1.1 Was ist ein Mainframe

Für die elektronische Datenverarbeitung (EDV) im Businesskontext können verschiedene Technologien eingesetzt werden. Das *Mainframe* »ist ein zentrales Datenlager«[2], welches zur konzentrierten Datenverarbeitung eingesetzt wird. Es ist besonders geeignet für Prozesse, die nicht interaktiv sind und einen hohen Datendurchsatz haben, z.B. Online Transaction Processing (OLTP) und Online Analytical Processing (OLAP).

#### Unterschied zwischen Mainframe und x64

Möchte man zentral Daten verarbeiten oder Software abspielen, so ist ein Server die einfachste Lösung. Ein klassischer Server ist ein Computer mit derselben Struktur wie ein herkömmlicher PC nach der von-Neumann-Architektur. Wie ein PC ist er vielseitig und einfach zu betreiben.

Ein *Mainframe*, zu Deutsch Großrechner, verfügt dagegen über andere Komponenten und eine andere Architektur. Er ist im Vergleich viel spezialisierter und wird nur für sehr konkrete Aufgaben verwendet, da es sehr schwierig ist, ein Mainframe zu programmieren und zu betreiben.

2.1. Z SYSTEMS 4

Server	Mainframe
Server verfügen nur über einfache Kompo-	Weil sie aus besonderen Komponenten be-
nenten. Diese sind auf dem Markt in großer	stehen, die nur bei wenigen Herstellern ver-
Stückzahl vorhanden und dadurch günstig	fügbar sind, sind Mainframes teuer in der
in der Anschaffung.	Anschaffung. Heute sind $> 99~\%$ aller Main-
	frames von IBM.
Die HW ist allgemein und vielseitig ein-	Die HW ist komplex und spezialisiert.
setzbar. Interne Prozesse sind in SW im-	Für jede Art von Operation, z.B. OS,
plementiert. Selbst dedizierte HW, wie eine	In-/Output, Datenbank-SW oder Java-
Graphical Processing Unit oder eine Ten-	Applikation [2], ist eigene HW vorhanden.
sor Processing Unit, ist nicht auf einen	
bestimmten Anwendungsfall beschränkt.	
Server können flexibel für jede Aufgabe	Spezialisierte HW führt zu einem hohen
eingesetzt. Server sind besser bei benut-	Datendurchsatz. OLTP, z.B. Banktransak-
zerspezifischen Anwendungen mit hoher	tionen, und OLAP, z.B. statistische Ana-
Interaction.	lysen auf dem DWH, laufen wesentlich
	schneller.
Im Vergleich zu PCs verfügen Server über	Ein einzelnes Mainframe verfügt bereits
eine starke Netzwerkkarte und können so	über eine hohe Anzahl an Prozessoren.
miteinander verbunden werden. Ein klei-	Mehrere Mainframes zusammen ergeben
ner Verbund wird als <i>Cluster</i> , ein großer	einen Sysplex
Verbund als Serverfarm bezeichnet. Für	
einen leistungsstarken Verbund wird eine	
hohe Anzahl an Servern benötigt.	
Downtime < 0.0000001~%	Downtime $\emptyset > 0,0001 \%$ [1], daher $\rightarrow \mathbb{Z} \langle \text{ für } \rangle$
	»zero Downtime«

Tabelle 2.1: Meine Tabelle

#### 2.1.2 Aufbau Mainframe

Obwohl ein Mainframe größer und leistungsstärker ist als ein Server, ist noch immer nicht leistungsstark genug, um die gesamte EDV eines Unternehmens zu beherrschen. Deswegen werden Mainframes ähnlich wie Server skaliert. Die beiden größten Skalierungsmethoden sind der physische Zusammenschluss mehrerer Maschinen und die logische Aufteilung zur Lastverteilung.

#### Sysplex

Ein System Complex (Sysplex) besteht aus mehreren Mainframe-Maschinen, die »durch Spezialisierte HW zu einer Einheit zusammengeschlossen sind«. Innerhalb eines Sysplex können Mainframes Ressourcen teilen, z.B. Hauptspeicher, Datenbanken und I/O - Schnittstellen. Prozesse können von einer beliebigen Kombination von Maschinen innerhalb des Sysplex ausgeführt werden, wodurch die Arbeitslast immer gleichmäßig verteilt wird und

2.2. Z/OS 5

bis in die hohe Auslastung skaliert. Während Server bereits bei 20 % Auslastung langsamer werden, können Z Systems bis >90 % belastet werden.

Die Steigerung zum Sysplex ist der Parallel Sysplex. Das ist eine Implementation mittels Coupling Facilities (CF) unter dem OS z/OS. Eine CF ist eine logische Einheit innerhalb eines Mainframes, die dazu dient, Adressen zu übersetzen, Daten zu cachen und ggf. den Zugriff auf sie zu sperren. Sind alle Anwendungen für den Parallel Sysplex optimiert, »kann die Arbeitslast:

- dynamisch über alle Systeme verteilt werden
- vertikal und horizontal skaliert werden
- bei geplantem und ungeplantem Ausfall eines Systems verfügbar bleiben
- alle Systeme innerhalb des Setups als eins benutzen«[2]

In der Atruvia AGwerden mehrere Sysplexe verwendet. So gibt es unterschiedliche Sysplexe für Produktions- und Entwicklungsumgebung. Während dieser Bachelorarbeit wird ausschließlich auf dem **E-Plex**, welcher keine Produktion enthält, gearbeitet. Dies ist wichtig, um den laufenden Betrieb des Unternehmens nicht zu stören oder gar zu stoppen.

#### **LPAR**

Ähnlich wie virtuelle Maschinen auf einem Servercluster ausgeführt werden, wird die HW des Mainframes in logische Gruppen unterteilt. Eine »Logical Partition (LPAR) ist eine Gruppe an HW-Prozessoren, die ein OS ausführt«[2]. Die Unterteilung des physischen Systems wird über einen Hypervisor Typ 1 realisiert, eine Firmware, die in den Prozessor eingebaut ist und nicht Teil des OS ist. Innerhalb eines Parallel Sysplex können LPAR HW-Ressourcen wie Hauptspeicher teilen. Jede LPAR hat aber ihre eigenen Daten.

Der größte Vorteil einer LPAR besteht in der Isolation. Ihre Daten und Prozesse einer LPAR sind unabhängig von denen anderer LPAR. Dadurch erhält man Sicherheit und Integrität. Der Admin kann Zugriffe auf eine LPAR kontrollieren und Rechte dafür vergeben.

#### 2.2 Betriebssystem

Das OS z/OS ist speziell für IBM Z Systems entwickelt.

Werden Daten geteilt?

Warum
Performanc
Gewinn?

2.2. Z/OS 6

#### 2.2.1 Db2

rDB

Subsystem

2.2.2 TSO

REXX

#### 2.2.3 IWS

# 3. Aufbau Testumgebung

#### 3.1 Aufsetzen Testsystem

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### 3.2 Datenmigration

#### 3.2.1 DDL

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### 3.2.2 Datenmigration

drei Mig-Arten Namen Rolf fragen

# 4. Wie funktioniert eine Recovery

#### 4.1 aktuelle Backuptstrategie

#### **Fullbackup**

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### incemental Backup

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### Log

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### 4.1.1 Indizes: Copy oder Rebuild

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### 4.1.2 Activelog vs. Archivelog

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

# Literatur

- [1] Information Technology Intelligence Consulting, Hrsg. ITIC 2022 Global Server Hardware, Server OS Reliability Report. Website. 2022. URL: https://www.ibm.com/downloads/cas/VQ5B65YZ [besucht am 28.06.2023] [siehe S. 4].
- [2] IBM. Introduction to the New Mainframe: z/OS Basics. Redbooks. IBM, 2009 [siehe S. 3–5].