

# Backup- und Recoverystrategie für Db2 z/OS auf dem IBM Mainframe mittels IBM- und BMC-Tools

## BACHELORARBEIT

für die Prüfung zum

Bachelor of Science

des Studienganges Informatik / Angewandte Informatik

an der

Dualen Hochschule Baden-Württemberg Karlsruhe

von

**Patrick Frey**

Abgabedatum 4. September 2023

Bearbeitungszeitraum

12 Wochen

Matrikelnummer

3946606

Kurs

tinf20b2

Ausbildungsfirma

Atruvia AG

Karlsruhe

Betreuer der Ausbildungsfirma

Rolf Merkle

Gutachter der Studienakademie

Michael Vetter

## Erklärung

Ich versichere hiermit, dass ich meine Bachelorarbeit mit dem Thema: »Backup- und Recoverystrategie für Db2 z/OS auf dem IBM Mainframe mittels IBM- und BMC-Tools« selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt. \_\_\_\_\_

\_\_\_\_\_  
Ort      Datum

\_\_\_\_\_  
Unterschrift

## Sperrvermerk

Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungsprozesses und des Evaluationsverfahrens zugänglich gemacht werden, sofern keine anderslautende Genehmigung vom Dualen Partner vorliegt.

# Inhaltsverzeichnis

<b>1</b>	<b>Aufgabe und Ziel</b>	<b>1</b>
<b>2</b>	<b>Einführung ins Mainframe</b>	<b>3</b>
2.1	Z Systems . . . . .	3
2.1.1	Was ist ein Mainframe . . . . .	3
2.1.2	Aufbau Mainframe . . . . .	4
2.2	z/OS . . . . .	5
2.2.1	Db2 . . . . .	6
2.2.2	TSO . . . . .	6
2.2.3	IWS . . . . .	6
<b>3</b>	<b>Migration</b>	<b>7</b>
3.1	Db2W . . . . .	7
3.2	Datenmigration . . . . .	7
3.2.1	DDL . . . . .	7
3.2.2	Datenmigration . . . . .	7
<b>4</b>	<b>Recoverystrategie</b>	<b>8</b>
4.1	aktuelle Backuptstrategie . . . . .	8
4.1.1	Indizes . . . . .	8
4.1.2	Activelog vs. Archivelog . . . . .	8

# Abbildungsverzeichnis

# Tabellenverzeichnis

2.1	Meine Tabelle . . . . .	4
-----	-------------------------	---

# Abkürzungsverzeichnis

<b>SLA</b> Service Level Agreements . . . . .	1
<b>EDV</b> elektronische Datenverarbeitung . . . . .	3
<b>HW</b> Hardware	
<b>SW</b> Software	
<b>OLAP</b> Online Analytical Processing . . . . .	3
<b>OLTP</b> Online Transaction Processing . . . . .	3
<b>OS</b> Betriebssystem	
<b>DWH</b> Data Ware House	
<b>LPAR</b> Logical Partition . . . . .	5
<b>Sysplex</b> System Complex . . . . .	4
<b>CF</b> Coupling Facility . . . . .	5
<b>DB</b> Datenbank . . . . .	1
<b>TS</b> Tablespace . . . . .	1

---

<b>DBMS</b> Datenbankmanagementsystem . . . . .	1
---	---

# 1. Aufgabe und Ziel

## Umfeld

Die Atruvia AG ist der IT-Dienstleister der genossenschaftlichen Finanzgruppe. Die Atruvia AG ist in Geschäftsfeldern und Servicefeldern unterteilt. Das Servicefeld Plattformservices stellt die technischen Grundlagen für dritte, wertschöpfende Dienstleistungen bereit. Der Plattformservice Databaseservices betreibt alle zentralen Datenbanken, die für die Kerngeschäftsprozesse benötigt werden. Die vorwiegende Technologie ist Db2 z/OS von IBM. Während die meisten modernen Datenbankmanagementsysteme (DBMS), wie Oracle oder MSSQL, auf Servern laufen, setzt IBM auf sein eigenes Mainframe, das *Z Systems*.

## Aufgabe

Ein Datenbanksystem muss zu jeder Zeit wiederherstellbar sein. Äußere Einflüsse wie Naturkatastrophen, innere Störungen durch Hardwareschäden oder menschliches Fehlverhalten kann dazu führen, dass Daten korrupt, inkonsistent oder fachlich falsch sind. In diesen Fällen muss ein funktionierender Stand wiederhergestellt werden. Das Unternehmen hat dahingehend Service Level Agreements (SLA) mit den Kunden, welche die erlaubte nicht-Verfügbarkeit vorgeben. Um das sicherzustellen, soll eine Backup- und Recoverystrategie entwickelt werden. Bestandteil dieser Strategie sind verschiedene Parameter wie Copy-Bestandteile und verwendetes Tool. Als Nebenfaktoren sollen Speicherkomplexität des Backups und die Laufzeitkomplexität der Recovery berücksichtigt werden.

Mittels Zwischenergebnissen werden Kosten bestimmt und eine Laufzeitprognose erstellt. Diese dienen der Vorbereitung auf den finalen Schritt: Die Recovery eines gesamten Datenbanksystems.

Zur Ergebnisverifikation wird ein Tool entwickelt, welches die Integrität des reconvertierten Subsystems überprüft. Dafür müssen betroffenen Datenbanken (DBs) und Tablespace (TSs) identifiziert und auf Vollständigkeit geprüft werden.

## gewünschtes Ergebnis

Konkretisierung

Am Ende soll eine praktikable Recoverystrategie stehen. Eine Empfehlung soll ausgeprochen werden über die Durchführung der Recovery, welche Methode, welche Tools sollen verwendet werden. Dies ist über Speicher- und Laufzeitkomplexität zu begründen.



Außerdem muss das Ergebnis verifiziert werden. Dafür muss die eigens entwickelte Anwendung einen Healthcheck ausführen indem die Vollständigkeit des Backups geprüft wird. Zusätzlich soll die Komplexität einer Recovery prognostiziert werden.

## 2. Einführung ins Mainframe

### 2.1 Z Systems

Im Rahmen dieser Bachelorarbeit wird keine dezentrale Software entwickelt, sondern zentral auf dem IBM Mainframe (früher Großrechner) entwickelt. In der Atruvia AG wird das Flaggschiff von IBM eingesetzt, das *Z Systems*, aktuell in der 15. Generation. Das Mainframe ist eine besondere Art Computer, die mitunter ähnliche Aufgaben erfüllt wie ein Server. Jedoch treten zum Teil wesentliche Unterschiede auf.

#### 2.1.1 Was ist ein Mainframe

Für die elektronische Datenverarbeitung (EDV) im Businesskontext können verschiedene Technologien eingesetzt werden. Das *Mainframe* »ist ein zentrales Datenlager« [redbook.1], welches zur konkurrierende Datenverarbeitung eingesetzt wird. Es ist besonders geeignet für Prozesse, die einen hohen Datendurchsatz haben, z.B. Online Transaction Processing (OLTP), Online Analytical Processing (OLAP) und Batch.

#### Unterschied zwischen Mainframe und x64

Möchte man zentral Daten verarbeiten oder Software abspielen, so ist ein Server die einfachste Lösung. Ein klassischer Server ist ein Computer mit derselben Struktur wie ein herkömmlicher PC nach der von-Neumann-Architektur. Wie ein PC ist er vielseitig und einfach zu betreiben.

Ein *Mainframe*, zu Deutsch Großrechner, verfügt dagegen über andere Komponenten und eine andere Architektur. Er ist im Vergleich viel spezialisierter und wird nur für sehr konkrete Aufgaben verwendet, da es schwieriger ist, ein Mainframe zu programmieren und zu betreiben.

Server	Mainframe
Server verfügen nur über einfache Komponenten. Diese sind auf dem Markt in großer Stückzahl vorhanden und dadurch günstig in der Anschaffung.	Weil sie aus besonderen Komponenten bestehen, die nur bei wenigen Herstellern verfügbar sind, sind Mainframes teuer in der Anschaffung. Heute sind > 99 % aller Mainframes von IBM.
Die HW ist allgemein und vielseitig einsetzbar. Interne Prozesse sind in SW implementiert. Selbst dedizierte HW, wie eine Graphical Processing Unit oder eine Tensor Processing Unit, ist nicht auf einen bestimmten Anwendungsfall beschränkt.	Die HW ist komplex und spezialisiert. Für jede Art von Operation, z.B. OS, In-/Output, Datenbank-SW oder Java-Applikation [ <b>redbook.1</b> ], ist eigene HW vorhanden.
Server können flexibel für jede Aufgabe eingesetzt. Server sind besser bei benutzerspezifischen Anwendungen mit hoher Interaktion.	Spezialisierte HW führt zu einem hohen Datendurchsatz. OLTP, z.B. Banktransaktionen, und OLAP, z.B. statistische Analysen auf dem DWH, laufen wesentlich schneller.
Im Vergleich zu PCs verfügen Server über eine starke Netzwerkkarte und können so miteinander verbunden werden. Ein kleiner Verbund wird als <i>Cluster</i> , ein großer Verbund als <i>Serverfarm</i> bezeichnet. Für einen leistungsstarken Verbund wird eine hohe Anzahl an Servern benötigt.	Ein einzelnes Mainframe verfügt bereits über eine hohe Anzahl an Prozessoren. Mehrere Mainframes zusammen ergeben einen <i>Sysplex</i>
Downtime $\emptyset > 0,0001$ % [ <b>itic</b> ], daher »Z für »zero Downtime«	Downtime $< 0,0000001$ %

Tabelle 2.1: Meine Tabelle

### 2.1.2 Aufbau Mainframe

Obwohl ein Mainframe größer und leistungsstärker ist als ein Server, ist noch immer nicht leistungsstark genug, um die gesamte EDV eines Unternehmens zu beherrschen. Deswegen werden Mainframes ähnlich wie Server skaliert. Die beiden größten Skalierungsmethoden sind der physische Zusammenschluss mehrerer Maschinen und die logische Aufteilung zur Lastverteilung.

#### Sysplex

Ein System Complex (Sysplex) besteht aus mehreren Mainframe-Maschinen, die »durch Spezialisierte HW zu einer Einheit zusammengeschlossen sind«. Innerhalb eines Sysplex können Mainframes Ressourcen teilen, z.B. Hauptspeicher, Datenbanken und I/O - Schnittstellen. Prozesse können von einer beliebigen Kombination von Maschinen innerhalb des Sysplex ausgeführt werden, wodurch die Arbeitslast immer gleichmäßig verteilt wird und

bis in die hohe Auslastung skaliert. Während Server bereits bei 20 % Auslastung langsamer werden, können Z Systems bis > 90 % belastet werden.

Die Steigerung zum Sysplex ist der *Parallel Sysplex*. Das ist eine Implementation mittels Coupling Facilities (CF) unter dem *OS z/OS*. Eine CF ist eine logische Einheit innerhalb eines Mainframes, die dazu dient, Adressen zu übersetzen, Daten zu cachen und ggf. den Zugriff auf sie zu sperren. Sind alle Anwendungen für den Parallel Sysplex optimiert, »kann die Arbeitslast:

- dynamisch über alle Systeme verteilt werden
- vertikal und horizontal skaliert werden
- bei geplantem und ungeplantem Ausfall eines Systems verfügbar bleiben
- alle Systeme innerhalb des Setups als eins benutzen«[redbook.1]

In der Atruvia AG werden mehrere Sysplexe verwendet. So gibt es unterschiedliche Sysplexe für Produktions- und Entwicklungsumgebung. Während dieser Bachelorarbeit wird ausschließlich auf dem **E-Plex**, welcher keine Produktion enthält, gearbeitet. Dies ist wichtig, um den laufenden Betrieb des Unternehmens nicht zu stören oder gar zu stoppen.

## LPAR

Ähnlich wie virtuelle Maschinen auf einem Servercluster ausgeführt werden, wird die HW des Mainframes in logische Gruppen unterteilt. Eine »Logical Partition (LPAR) ist eine Gruppe an HW-Prozessoren, die ein OS ausführt«[redbook.1]. Die Unterteilung des physischen Systems wird über einen Hypervisor Typ 1 realisiert, eine Firmware, die in den Prozessor eingebaut ist und nicht Teil des OS ist. Innerhalb eines Parallel Sysplex können LPAR HW-Ressourcen wie Hauptspeicher teilen. Jede LPAR hat aber ihre eigenen Daten.

Der größte Vorteil einer LPAR besteht in der Isolation. Ihre Daten und Prozesse einer LPAR sind unabhängig von denen anderer LPAR. Dadurch erhält man Sicherheit und Integrität. Der Admin kann Zugriffe auf eine LPAR kontrollieren und Rechte dafür vergeben.

Werden  
Da-  
ten  
ge-  
teilt?

## 2.2 Betriebssystem

Das OS *z/OS* ist speziell für IBM Z Systems entwickelt.

Warum  
Performanc  
Gewinn?

### **2.2.1 Db2**

RACF

rDB

Subsystem

### **2.2.2 TSO**

REXX

### **2.2.3 IWS**

## 3. Aufbau Testumgebung

### 3.1 Aufsetzen Testsystem

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

### 3.2 Datenmigration

#### 3.2.1 DDL

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### 3.2.2 Datenmigration

drei  
Mig-  
Arten  
Na-  
men  
Rolf  
fra-  
gen

## 4. Wie funktioniert eine Recovery

### 4.1 aktuelle Backupstrategie

#### **Fullbackup**

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### **incemental Backup**

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### **Log**

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### **4.1.1 Indizes: Copy oder Rebuild**

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.

#### **4.1.2 Activelog vs. Archivelog**

Die CPU hat keinen direkten Zugriff auf den Hauptspeicher. Stattdessen wird der Hauptspeicher-Cache dazwischengeschaltet. Die CPU greift nur auf diesen Cache zu. Der Hauptspeicher wird dann durch den Cache aktualisiert.